

#### DATOS GENERALES DEL ESTUDIANTE

|                           |                                                        |
|---------------------------|--------------------------------------------------------|
| <b>Nombre Estudiante</b>  | Frank Edward Daza Gonzalez                             |
| <b>Programa Académico</b> | Maestría en Inteligencia Artificial y Ciencia de Datos |
| <b>Cédula</b>             | 1144028994                                             |
| <b>Código Estudiantil</b> | 22500207                                               |
| <b>Correo</b>             | frank_edw.daza@uao.edu.co                              |

#### DATOS GENERALES DEL DIRECTOR

|                          |                                    |
|--------------------------|------------------------------------|
| <b>Nombre Director</b>   | Julián Hurtado López               |
| <b>Correo</b>            | jhurtado@uao.edu.co                |
| <b>Nombre Codirector</b> | Alba Marcela Herrera Trujillo      |
| <b>Correo</b>            | alba.herrera@correounivalle.edu.co |

#### DATOS DEL ANTEPROYECTO

| TÍTULO DEL PROYECTO                                                                                                                                                                   |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Evaluación de la Eficiencia de una Arquitectura Híbrida CNN-VQC para el Diagnóstico de Tumores Cerebrales en Imágenes de Resonancia Magnética en Escasez de Datos                     |
| PALABRAS CLAVES/KEY WORDS                                                                                                                                                             |
| Aprendizaje Automático Cuántico, Convolutional Neural Networks, Circuitos Cuánticos Variacionales, Hybrid Quantum-Classical Neural Networks, Tumores Cerebrales, Resonancia Magnética |
| RESUMEN                                                                                                                                                                               |

El auge de las Redes Neuronales Convolucionales (CNN) ha revolucionado el diagnóstico médico. Sin embargo, arquitecturas recientes se centran en maximizar la precisión utilizando grandes volúmenes de datos, ignorando la escasez de información en entornos clínicos reales (*Low-Data regimes*). Este proyecto investiga la viabilidad de una arquitectura híbrida cuántico-clásica para resolver esta “paradoja de los datos”. A diferencia de trabajos recientes que entrenan modelos híbridos desde cero buscando explicabilidad, esta propuesta integra *Transfer Learning* (usando EfficientNet) con un Clasificador Cuántico Variacional (VQC) para mejorar la **eficiencia de datos**. La metodología contrastará el modelo híbrido frente a arquitecturas del estado del arte (EfficientNet-B0, ResNet-50) evaluando específicamente la capacidad de generalización al entrenar con solo el 10 %, 25 % y 50 % del dataset. La hipótesis central es que el componente cuántico permite obtener métricas competitivas con fracciones reducidas de datos, superando a los modelos clásicos propensos al sobreajuste en estos escenarios.

**EVALUACIÓN DE LA EFICIENCIA DE UNA ARQUITECTURA HÍBRIDA  
CNN-VQC PARA EL DIAGNÓSTICO DE TUMORES CEREBRALES EN  
IMÁGENES DE RESONANCIA MAGNÉTICA EN ESCASEZ DE DATOS**



**FRANK EDWARD DAZA GONZALEZ  
22500207**

**UNIVERSIDAD AUTÓNOMA DE OCCIDENTE  
FACULTAD DE INGENIERÍA Y CIENCIAS BÁSICAS  
PROGRAMA MAESTRÍA EN INTELIGENCIA ARTIFICIAL Y CIENCIA DE DATOS  
SANTIAGO DE CALI  
2026**

**EVALUACIÓN DE LA EFICIENCIA DE UNA ARQUITECTURA HÍBRIDA  
CNN-VQC PARA EL DIAGNÓSTICO DE TUMORES CEREBRALES EN  
IMÁGENES DE RESONANCIA MAGNÉTICA EN ESCASEZ DE DATOS**



**FRANK EDWARD DAZA GONZALEZ**

**Anteproyecto de grado para optar al título de  
Magíster en Inteligencia Artificial y Ciencia de Datos**

**Director**

**JULIAN HURTADO LÓPEZ**

**Doctor en Ingeniería**

**Codirector**

**ALBA MARCELA HERRERA TRUJILLO**

**Doctora en Física**

**UNIVERSIDAD AUTÓNOMA DE OCCIDENTE  
FACULTAD DE INGENIERÍA Y CIENCIAS BÁSICAS  
PROGRAMA MAESTRÍA EN INTELIGENCIA ARTIFICIAL Y CIENCIA DE DATOS  
SANTIAGO DE CALI  
2026**

## CONTENIDO

|                                                                                                    | pág.      |
|----------------------------------------------------------------------------------------------------|-----------|
| <b>INTRODUCCIÓN</b>                                                                                | <b>6</b>  |
| <b>1 PLANTEAMIENTO DEL PROBLEMA</b>                                                                | <b>7</b>  |
| 1.1 Pregunta de Investigación                                                                      | 7         |
| <b>2 OBJETIVOS</b>                                                                                 | <b>9</b>  |
| 2.1 Objetivo General                                                                               | 9         |
| 2.2 Objetivos Específicos                                                                          | 9         |
| <b>3 JUSTIFICACIÓN Y ALCANCE</b>                                                                   | <b>10</b> |
| <b>4 ANTECEDENTES Y ESTADO DEL ARTE</b>                                                            | <b>11</b> |
| <b>5 MARCO TEÓRICO</b>                                                                             | <b>13</b> |
| 5.1 Deep Learning y Eficiencia Computacional                                                       | 13        |
| 5.1.1 Arquitecturas de Referencia: El Reto del Escalado                                            | 13        |
| 5.2 Fundamentos de Cómputo Cuántico Aplicado (QML)                                                 | 14        |
| 5.2.1 Circuitos Cuánticos Variacionales (VQC)                                                      | 14        |
| 5.2.2 Mitigación de Barren Plateaus y Estrategias de Inicialización                                | 15        |
| 5.3 Transferencia de Aprendizaje Híbrido (Hybrid Transfer Learning)                                | 16        |
| <b>6 DISEÑO METODOLÓGICO</b>                                                                       | <b>17</b> |
| 6.1 Fase 1: Desarrollo de la Arquitectura Híbrida CNN-VQC (Objetivo Específico 1)                  | 17        |
| 6.2 Fase 2: Establecimiento de Líneas Base y Preparación de Datos (Objetivo Específico 2)          | 18        |
| 6.3 Fase 3: Evaluación de Generalización en Escenarios de Escasez de Datos (Objetivo Específico 3) | 18        |
| 6.4 Cronograma de Actividades                                                                      | 19        |
| <b>7 RECURSOS Y ASPECTOS ECONÓMICOS</b>                                                            | <b>21</b> |
| <b>REFERENCIAS</b>                                                                                 | <b>22</b> |

## INTRODUCCIÓN

El diagnóstico por imagen es una piedra angular de la medicina moderna, siendo la Imagen por Resonancia Magnética (MRI, *Magnetic Resonance Imaging*) la modalidad de referencia para la detección y caracterización de tumores cerebrales debido a su alto contraste en tejidos blandos. En la última década, la Inteligencia Artificial (IA), y específicamente el Aprendizaje Profundo (DL, *Deep Learning*), ha transformado este campo, permitiendo el desarrollo de sistemas de diagnóstico asistido por computador (CAD, *Computer-Aided Diagnosis*) con una precisión comparable a la de expertos humanos. Las Redes Neuronales Convolucionales (CNN, *Convolutional Neural Networks*) se han establecido como la tecnología líder para estas tareas (He et al., 2016). Sin embargo, el despliegue efectivo de estos modelos enfrenta un obstáculo significativo: la “paradoja de los datos”. Mientras que las arquitecturas de vanguardia (SOTA, *State of the Art*) requieren millones de imágenes para ajustar sus parámetros sin caer en el sobreajuste (*overfitting*), la disponibilidad de datos médicos etiquetados de alta calidad es intrínsecamente escasa y costosa de obtener (Litjens et al., 2017; Willemink et al., 2020; Esteva et al., 2019). Esta brecha limita la aplicabilidad de modelos masivos en patologías poco frecuentes o en centros médicos con bases de datos limitadas.

El Aprendizaje Automático Cuántico (QML, *Quantum Machine Learning*) emerge como una frontera prometedora para abordar este problema. En la actual era de dispositivos NISQ (*Noisy Intermediate-Scale Quantum*) (Preskill, 2018; Bharti et al., 2022), los modelos híbridos cuántico-clásicos proponen una sinergia innovadora: utilizar redes clásicas pre-entrenadas para la extracción de características robustas (Transfer Learning) y circuitos cuánticos variacionales (VQC, *Variational Quantum Classifier*) para el procesamiento final. La hipótesis subyacente sugiere que la alta expresividad de los circuitos cuánticos en espacios de Hilbert de alta dimensión podría permitir una mejor generalización con menos datos de entrenamiento que los clasificadores clásicos tradicionales (Mari et al., 2020b; Abbas et al., 2021).

Este proyecto propone el diseño y evaluación de una arquitectura híbrida VQC-CNN aplicada a la clasificación multiclase de tumores cerebrales. A diferencia de estudios previos enfocados únicamente en la reducción de parámetros, esta investigación busca establecer si el componente cuántico aporta una ventaja real en términos de **eficiencia de datos**. Se contrastará el modelo propuesto frente a arquitecturas clásicas optimizadas como EfficientNet (Tan and Le, 2019) bajo condiciones de escasez de datos, validando el potencial del QML para entornos médicos reales (Shahjalal et al., 2025; Khan et al., 2024).

## 1. PLANTEAMIENTO DEL PROBLEMA

La clasificación automatizada de imágenes médicas mediante CNNs ha alcanzado hitos significativos. Autores seminales como [He et al. \(2016\)](#) sentaron las bases con arquitecturas profundas, las cuales, junto con variantes modernas optimizadas para MRI, han demostrado alta precisión. Sin embargo, el paradigma actual de “más profundo es mejor” conlleva desafíos críticos. La tendencia dominante ha sido el escalado masivo de modelos. Arquitecturas estándar como ResNet-50 contienen decenas de millones de parámetros. Si bien modelos más modernos como EfficientNet ([Tan and Le, 2019](#)) han optimizado la relación precisión-parámetros, persiste una barrera fundamental: el Riesgo de Sobreajuste en Escenarios de Escasez de Datos.

El análisis de imágenes médicas se enfrenta a la disponibilidad limitada de conjuntos de datos. Entrenar modelos con millones de parámetros sobre datasets médicos pequeños (cientos o pocos miles de imágenes) conduce frecuentemente al sobreajuste, donde la red memoriza el ruido del entrenamiento en lugar de aprender características generalizables. Aunque técnicas clásicas como el aumento de datos (*data augmentation*) mitigan esto parcialmente, no resuelven la ineficiencia estructural del aprendizaje clásico en regímenes de pocos datos (*Few-Shot* o *Low-Data regimes*).

Aquí es donde el QML surge como una alternativa disruptiva. Teóricamente, los Circuitos Cuánticos Variacionales (VQC) pueden procesar información aprovechando el entrelazamiento y la superposición, lo que les otorga una mayor capacidad de representación (expresividad) por parámetro que las redes neuronales clásicas ([Schuld and Killoran, 2019](#)). Estudios recientes como los de [Shahjalal et al. \(2025\)](#) sugieren que esta ventaja teórica puede traducirse en rendimiento práctico en datasets médicos. Sin embargo, existe un vacío en la literatura experimental: ¿Se traduce esta ventaja teórica en un mejor rendimiento práctico cuando los datos son escasos? La mayoría de los estudios actuales comparan modelos cuánticos contra redes clásicas básicas, lo que infla la percepción de ventaja. Faltan evaluaciones rigurosas que contrasten las arquitecturas híbridas frente a modelos clásicos eficientes (como EfficientNet-B0) utilizando estrategias de *Transfer Learning* en escenarios de datos limitados.

### 1.1 PREGUNTA DE INVESTIGACIÓN

¿Puede una arquitectura híbrida cuántico-clásica, basada en Transfer Learning, demostrar una capacidad de generalización superior a la de arquitecturas clásicas del

estado del arte (como EfficientNet-B0 y ResNet-50) en escenarios de entrenamiento con escasez de datos, manteniendo métricas competitivas?



## 2. OBJETIVOS

### 2.1 OBJETIVO GENERAL

Evaluar la eficiencia de una arquitectura híbrida cuántico-clásica para la clasificación multiclase de tumores cerebrales por medio de MRI, comparando su desempeño frente a arquitecturas clásicas en escenarios de escasez de datos.

### 2.2 OBJETIVOS ESPECÍFICOS

1. Desarrollar una arquitectura híbrida que integre una red neuronal clásica pre-entrenada basada en EfficientNet-B0 (extractor de características) con un circuito cuántico variacional (VQC) utilizando técnicas de *Angle Embedding* y *Strongly Entangling Layers*.
2. Entrenar los modelos de referencia clásicos: EfficientNet-B0 y ResNet-50, estableciendo líneas base robustas mediante *Transfer Learning* y entrenamiento con el conjunto completo de datos.
3. Evaluar comparativamente la exactitud del modelo híbrido y los modelos clásicos en escenarios de escasez de datos (10 %, 25 % y 50 % del *dataset*), utilizando validación cruzada estratificada y análisis estadístico.

### 3. JUSTIFICACIÓN Y ALCANCE

Este proyecto se justifica por la necesidad de democratizar el uso de IA en medicina, donde la recolección de “Big Data” no siempre es viable. Si se valida que los modelos híbridos aprenden mejor con menos datos, esto tendría un impacto directo en la capacidad de diagnosticar enfermedades raras o en la implementación de sistemas en hospitales pequeños. El proyecto aborda el problema desde la perspectiva del *Hybrid Transfer Learning* (Mari et al., 2020b). A diferencia de intentar entrenar redes cuánticas desde cero (lo cual sufre de problemas como “Barren Plateaus”, McClean et al. (2018)), el uso de redes pre-entrenadas permite aprovechar la potencia de la visión clásica y combinarla con la expresividad del espacio de características cuántico. Se pretende evitar la generación de expectativas infundadas respecto a la supremacía cuántica actual; por el contrario, el objetivo es cuantificar rigurosamente en qué nicho (específicamente *Low-Data*) la tecnología NISQ actual puede ofrecer una ventaja tangible (Gupta et al., 2025).

#### Alcance:

1. **Tarea:** Clasificación multiclase mediante MRI (4 clases: glioma, meningioma, pituitario, no tumor). No se aborda la segmentación.
2. **Datos:** Uso exclusivo de datasets públicos de MRI, garantizando la reproducibilidad (Nickparvar, 2023).
3. **Enfoque Experimental:** Validación cruzada entrenando con fracciones del dataset total para simular escasez de datos.
4. **Tecnología:** Implementación en simuladores cuánticos integrados con PyTorch. No se requiere hardware cuántico real, enfocándose en la validación algorítmica y de arquitectura.

Independientemente del resultado experimental, este proyecto garantiza:

- **Contribución metodológica:** Protocolo reproducible de evaluación de HQCNN (*Hybrid Quantum-Classical Neural Networks*) en régimen de datos limitados.
- **Contribución empírica:** Caracterización cuantitativa del balance entre la exactitud y el conjunto de datos.
- **Contribución práctica:** Guía basada en evidencia sobre cuándo considerar (o no) soluciones QML en diagnóstico médico.

#### 4. ANTECEDENTES Y ESTADO DEL ARTE

Tradicionalmente, las arquitecturas de Redes Neuronales Convolucionales (CNN) clásicas, tales como ResNet y EfficientNet, han dominado el estado del arte en la clasificación automatizada de tumores cerebrales a partir de neuroimágenes, logrando niveles de exactitud sobresalientes en la literatura asistida por “Big Data” (Shahriyar and Tanbhir, 2025; Tan and Le, 2019). No obstante, la dependencia de estas redes profundas hacia volúmenes masivos de datos para evitar el sobreajuste (*overfitting*) representa una barrera crítica en la práctica clínica, dada la escasez y el costo intrínseco de obtención de estudios médicos etiquetados (Willemink et al., 2020).

Para mitigar esta vulnerabilidad fundamental mediante una mejor representación del espacio de características con pocos parámetros, la investigación ha comenzado a integrar el Aprendizaje Automático Cuántico (QML) con la visión clásica. En el área de clasificación de tejidos médicos con tecnologías cuánticas, Lusnig et al. (2024) propusieron un modelo híbrido basado en redes neuronales cuánticas para diagnosticar la esteatosis hepática a partir de biopsias bajo un marco de aprendizaje federado. En sus resultados, reportaron una precisión diagnóstica del 97 % (superando a una ResNet-18 convencional por un 1.8 %) y mantuvieron una tasa de falsos negativos inferior al 5 %. Sus principales ventajas radican en que las capas cuánticas mejoraron la capacidad de generalización y convergencia al operar con conjuntos de datos clínicos reducidos, mientras que su arquitectura solucionaba la restricción de privacidad de la data inter-hospitalaria. Como limitación, este desarrollo se centró en cortes histopatológicos bidimensionales, dejando abierto el desafío de su escalabilidad computacional en entornos volumétricos de alta demanda e intrincadas texturas, tales como las presentes en resonancias magnéticas craneales (MRI).

Para neurooncología específicamente, Ait Haddou and Bennai (2025) presentaron recientemente el modelo HQCM-EBTC para el cribado de tumores cerebrales, logrando una alta precisión (96.48 %) y destacada explicabilidad mediante mapas de atención. Sin embargo, su enfoque utiliza una CNN personalizada entrenada desde cero con el dataset completo (*Full Data*), sin evaluar empíricamente el rendimiento en verdaderos escenarios de escasez de datos, lo cual es el desafío transversal en el dominio médico. Además, su esquema comparativo se limitó a una contraparte clásica básica elaborada por los mismos investigadores, y no frente a arquitecturas del estado del arte refinadas mediante *Transfer Learning*.

Las revisiones sistemáticas sobre clasificación de neuroimágenes afirman que la

ventaja a corto plazo del QML híbrido no reside en superar la exactitud absoluta de las CNN pre-entrenadas con millones de capas de información, sino en expresar la eficiencia para alcanzar Generalización en regímenes *Low-Data* ([Shahriyar and Tanbir, 2025](#); [Khan et al., 2024](#)). Arquitecturas HQCNN análogas han esbozado esta superioridad paramétrica sobre modelos clásicos base ([Shahjalal et al., 2025](#)), pero persiste un notable vacío empírico: dichas redes cuánticas raramente demuestran su resiliencia bajo rigurosas comparativas frente a los extractores de características hiper-optimizados vigentes —como representaría el uso de *Fine-tuning* sobre un EfficientNet-B0— en regímenes de entrenamiento severamente limitados. Este es el nicho en el que el presente proyecto evaluará si la Transferencia de Aprendizaje Cuántico-Clásica materializa una ventaja tangible para los diagnósticos de tumores cerebrales bajo escasez de datos.

## 5. MARCO TEÓRICO

El marco teórico de esta investigación se articula sobre la convergencia de dos paradigmas computacionales: el Aprendizaje Profundo (*Deep Learning*) para el procesamiento de imágenes y el Cómputo Cuántico Variacional (VQC). A continuación, se fundamentan los principios matemáticos y arquitectónicos que sustentan la propuesta de una red híbrida eficiente.

### 5.1 DEEP LEARNING Y EFICIENCIA COMPUTACIONAL

Las Redes Neuronales Convolucionales (CNN) constituyen el estado del arte en tareas de visión por computador. Su arquitectura se inspira en la organización del córtex visual biológico y se basa matemáticamente en la operación de convolución discreta. Dada una imagen de entrada  $I$  y un filtro (kernel)  $K$  de dimensiones  $(2k + 1) \times (2k + 1)$ , el mapa de características  $S$  en la posición  $(i, j)$  se define como:

$$S(i, j) = (I * K)(i, j) = \sum_{m=-k}^k \sum_{n=-k}^k I(i + m, j + n) K(m, n) \quad (1)$$


Esta operación permite la extracción de características locales (bordes, texturas) con invarianza a la traslación, reduciendo drásticamente el número de parámetros respecto a las redes totalmente conectadas (MLP). Sin embargo, la demanda de precisión ha llevado a un escalado masivo de estos modelos.

#### 5.1.1 Arquitecturas de Referencia: El Reto del Escalado

Para contextualizar la eficiencia, se analizan dos familias de arquitecturas clave en la literatura:

- **ResNet (Residual Networks):** Introducida por [He et al. \(2016\)](#), esta arquitectura resolvió el problema de la degradación del gradiente en redes profundas mediante la introducción de “conexiones residuales”. Estas permiten que el flujo de información salte capas ( $x_{l+1} = F(x_l) + x_l$ ), facilitando el entrenamiento de modelos muy profundos (ej. ResNet-50, ResNet-101), aunque a costa de un alto número de parámetros.
- **EfficientNet:** Propuesta por [Tan and Le \(2019\)](#), representa el estado del arte en eficiencia clásica. Los autores demostraron que existe una relación óptima entre la profundidad ( $\alpha$ ), el ancho ( $\beta$ ) y la resolución ( $\gamma$ ) de la red. Mediante un método de “Escalado Compuesto” (*Compound Scaling*), EfficientNet-B0 logra un rendimiento superior a ResNet-50 con una reducción de parámetros de

orden de magnitud ( $\approx 5,3$  millones), sirviendo como el *baseline* clásico más exigente para esta investigación.



**Fig. 1.** : Estructura general de una Red Neuronal Convolutiva y el concepto de convolución.

## 5.2 FUNDAMENTOS DE CÓMPUTO CUÁNTICO APLICADO (QML)

El Quantum Machine Learning (QML) aprovecha las propiedades de la mecánica cuántica para el procesamiento de información. La unidad fundamental es el **qubit**, que se representa como un vector unitario en un espacio de Hilbert complejo bidimensional ( $\mathbb{C}^2$ ):

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad \text{donde } |\alpha|^2 + |\beta|^2 = 1 \quad (2)$$

La ventaja computacional potencial reside en la capacidad de procesar información en un espacio de estados que crece exponencialmente ( $2^N$ ) con el número de qubits  $N$ , permitiendo representar distribuciones de datos complejas que son intratables para modelos clásicos.


### 5.2.1 Circuitos Cuánticos Variacionales (VQC)

En la era actual NISQ (*Noisy Intermediate-Scale Quantum*), los algoritmos dominantes son los variacionales. Un VQC es un circuito cuántico parametrizado  $U(\theta)$  que funciona de manera análoga a una red neuronal:

1. **Codificación de Datos (Embedding):** Es el paso crítico de mapear datos clásicos  $x$  a un estado cuántico  $|\psi_x\rangle$ . Según [Dutta et al. \(2022\)](#), la elección del embedding determina la expresividad del modelo. Este proyecto utilizará

principalmente *Angle Embedding*, donde las características de entrada rotan los qubits en la esfera de Bloch ( $R_x(x_i)$ ), debido a su eficiencia en circuitos de baja profundidad.

2. **Ansatz Variacional:** Es la estructura del circuito compuesta por compuertas de rotación con parámetros entrenables  $\theta$  y compuertas de entrelazamiento (como CNOTs). La calidad del *Ansatz* define la capacidad del modelo para explorar el espacio de Hilbert y encontrar la solución óptima (Bergadano, 2024).
3. **Medición:** Finalmente, se mide el valor esperado de un observable (generalmente el operador Pauli-Z,  $\langle Z \rangle$ ) para colapsar el estado cuántico a un valor escalar clásico que pueda ser interpretado por la función de pérdida.



**Fig. 2. :** Esquema de un VQC: Codificación, Ansatz Variacional y Medición.

### 5.2.2 Mitigación de Barren Plateaus y Estrategias de Inicialización

Uno de los desafíos críticos en el entrenamiento de VQCs es el fenómeno de los *Barren Plateaus*, donde el gradiente de la función de costo desaparece exponencialmente con el número de qubits  $n$  (McClean et al., 2018). Para mitigar este riesgo y evitar conclusiones erróneas sobre la capacidad del modelo, este proyecto implementará las siguientes estrategias:

- **Inicialización por Bloques de Identidad:** Se inicializarán los parámetros del Ansatz de forma que las capas iniciales realicen una transformación cercana a la identidad. Esto garantiza que, al inicio del entrenamiento, el circuito no colapse en un estado altamente entrelazado aleatorio que anule el gradiente (Grant et al., 2019).

- **Restricción de la Varianza de Parámetros:** En lugar de una distribución uniforme  $[0, 2\pi]$ , se utilizará una inicialización normal con varianza controlada, centrada en valores que favorezcan la estabilidad del gradiente en las primeras épocas ([Holmes et al., 2022](#)).
- **Uso de Observables Locales:** Se emplearán funciones de costo basadas en mediciones locales (operadores de un solo qubit) en lugar de globales, lo cual ha demostrado teóricamente suavizar el paisaje de optimización y retrasar la aparición de mesetas ([Cerezo et al., 2021](#)).

### 5.3 TRANSFERENCIA DE APRENDIZAJE HÍBRIDO (HYBRID TRANSFER LEARNING)

El modelo propuesto se basa en el esquema de *Quantum Transfer Learning* formalizado por [Mari et al. \(2020a\)](#). En este enfoque, una red clásica pre-entrenada actúa como extractor de características, reduciendo la alta dimensionalidad de las MRI a un vector de características compacto. Este vector sirve como entrada para el VQC, que actúa como la capa clasificadora final ("Quantum Head").

Para entrenar este sistema híbrido de extremo a extremo (*end-to-end*), es necesario calcular el gradiente de la función de costo con respecto a los parámetros cuánticos. Esto se logra mediante la Regla de Cambio de Parámetros (*Parameter Shift Rule*), que permite evaluar el gradiente exacto de un circuito cuántico ejecutándolo con parámetros desplazados, integrándose así con el mecanismo de autogradiente de PyTorch ([Bergholm et al., 2018](#)).



## 6. DISEÑO METODOLÓGICO

La metodología propuesta se fundamenta en un enfoque experimental comparativo, estructurado en tres fases que corresponden directamente a los objetivos específicos del proyecto. Cada fase desglosa actividades críticas necesarias para validar la hipótesis de eficiencia de datos en arquitecturas híbridas.

### 6.1 FASE 1: DESARROLLO DE LA ARQUITECTURA HÍBRIDA CNN-VQC (OBJETIVO ESPECÍFICO 1)

Esta fase técnico-constructiva tiene como fin diseñar el modelo híbrido que combine la potencia de la visión por computadora clásica con la expresividad del cómputo cuántico.

- **A1. Configuración del Extractor de Características (Transfer Learning):** Se seleccionará la arquitectura *EfficientNet-B0* pre-entrenada con *ImageNet*. A diferencia de enfoques que entrenan CNNs desde cero ([Ait Haddou and Ben-nai, 2025](#)), el uso de pesos pre-entrenados es crucial para evitar el sobreajuste en escenarios de escasez de datos. Se congelarán las capas convolucionales para actuar como un extractor de características robusto, reduciendo la salida a un espacio latente compatible con el circuito cuántico.
- **A2. Diseño del Clasificador Cuántico Variacional (VQC):** Se implementará en la librería *PennyLane* un circuito cuántico parametrizado. Se define preliminarmente el uso de 4 qubits, estableciendo una correspondencia directa con las 4 clases de tumores del dataset (glioma, meningioma, pituitario y no tumor). La dimensionalidad del extractor clásico se reducirá mediante una capa densa para acoplarse a este número de qubits. Para determinar la configuración óptima, se realizarán experimentos variando la profundidad del *Ansatz* (*Strongly Entangling Layers*) con  $L \in \{2, 4, 6\}$  capas. Esta exploración permitirá cuantificar el compromiso entre la expresividad del modelo y el tiempo de simulación, buscando mitigar el riesgo de *Barren Plateaus* mediante una arquitectura de baja profundidad pero alta capacidad de entrelazamiento.
- **A3. Implementación de la Interfaz Híbrida:** Mediante el módulo *TorchLayer*, se integrará el circuito cuántico como la capa final de clasificación dentro del flujo de tensores de *PyTorch*, permitiendo el entrenamiento mediante el algoritmo de *backpropagation* clásico y la regla de cambio de parámetro (*Parameter Shift Rule*) para los gradientes cuánticos.

## 6.2 FASE 2: ESTABLECIMIENTO DE LÍNEAS BASE Y PREPARACIÓN DE DATOS (OBJETIVO ESPECÍFICO 2)

Esta fase garantiza que la comparación sea estadísticamente válida al establecer el rendimiento máximo que los modelos tradicionales pueden alcanzar con el conjunto de datos completo.

- **A4. Curaduría y Auditoría del Dataset:** Se validarán las 7023 imágenes del *Brain Tumor MRI Dataset*, realizando un análisis de balanceo de clases para asegurar que el entrenamiento no presente sesgos hacia categorías predominantes (ej. no tumor vs. glioma).
- **A5. Pipeline de Preprocesamiento y Aumento:** Se diseñará un flujo de transformación que incluya redimensionamiento a 224x224 píxeles, normalización estadística y técnicas de *Data Augmentation* (rotaciones leves y *flips*) para fortalecer la robustez de los modelos clásicos de referencia.
- **A6. Benchmark Clásico (SOTA):** Se entrenarán modelos *EfficientNet-B0* y *ResNet-50* utilizando el 100% del dataset. Estos resultados servirán como el límite superior de precisión contra el cual se contrastará la eficiencia del modelo cuántico en condiciones de escasez de datos.

## 6.3 FASE 3: EVALUACIÓN DE GENERALIZACIÓN EN ESCENARIOS DE ESCASEZ DE DATOS (OBJETIVO ESPECÍFICO 3)

Fase crítica orientada a medir la ventaja cuántica en términos de eficiencia de aprendizaje con pocos ejemplos (*Low-Data regimes*).

- **A7. Definición de Escenarios de Escasez:** Creación de subconjuntos de datos estratificados al 10 %, 25 % y 50 % del total del dataset.
- **A8. Implementación de Validación Cruzada Estratificada ( $k = 5$ ):** Para asegurar la validez estadística en regímenes de escasez de datos, se aplicará un esquema de *Stratified k-fold Cross-Validation* con  $k = 5$ . Esto implica que para cada fracción de datos (10 %, 25 %, 50 %), el subconjunto se dividirá en 5 particiones que mantienen la proporción de clases original. El modelo se entrenará y validará 5 veces, permitiendo reportar la media y la desviación estándar de las métricas, mitigando así el sesgo de selección.

- **A9. Evaluación Multimétrica:** Se calcularán métricas de desempeño que incluyan Accuracy y F1-Score, integrando de manera explícita la sensibilidad y especificidad por clase. Adicionalmente, se registrará sistemáticamente el tiempo de entrenamiento y latencia de inferencia.
- **A10. Análisis Estadístico de Resultados:** Se aplicarán pruebas de Análisis de Varianza (ANOVA) para determinar si las diferencias de desempeño observadas entre la arquitectura HQCNN y los modelos clásicos son estadísticamente significativas.
- **A11. Análisis Comparativo de Curvas de Aprendizaje y Brecha de Generalización:** Se realizará un monitoreo sistemático de la evolución de la función de pérdida (*Loss*) y la precisión (*Accuracy*) tanto en el conjunto de entrenamiento como en el de validación a lo largo de las épocas. El sobreajuste se cuantificará mediante la brecha de generalización ( $G = |Acc_{train} - Acc_{val}|$ ).
- **A12. Escritura y Documentación del Trabajo de Grado:** Se realizará la redacción del documento, integrando la revisión bibliográfica, el desglose metodológico, la síntesis de resultados y conclusiones.

## 6.4 CRONOGRAMA DE ACTIVIDADES

La ejecución de las fases y actividades descritas se proyecta en un periodo de ocho meses (2026), permitiendo tiempos adecuados para la iteración algorítmica y la experimentación computacional.

| Actividad / Mes (2026)                         | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 |
|------------------------------------------------|---|---|---|---|---|---|---|---|
| <b>Fase 1: Arquitectura</b>                    |   |   |   |   |   |   |   |   |
| A1. Configuración Extractor                    | X |   |   |   |   |   |   |   |
| A2. Diseño VQC                                 | X | X | X |   |   |   |   |   |
| A3. Integración Híbrida                        |   |   | X | X |   |   |   |   |
| <b>Fase 2: Benchmarking</b>                    |   |   |   |   |   |   |   |   |
| A4. Auditoría Dataset                          | X |   |   |   |   |   |   |   |
| A5. Pipeline Preprocesado                      |   | X |   |   |   |   |   |   |
| A6. Entrenamiento Baselines                    |   |   |   | X | X |   |   |   |
| <b>Fase 3: Experimentación y Documentación</b> |   |   |   |   |   |   |   |   |
| A7. Estratificación Escenarios                 |   |   |   |   | X |   |   |   |
| A8. Validación Cruzada ( $k = 5$ )             |   |   |   |   |   | X | X |   |
| A9. Registro de Tiempos                        |   |   |   |   |   |   | X | X |
| A10. Análisis ANOVA                            |   |   |   |   |   |   |   | X |
| A11. Análisis de Sobreajuste                   |   |   |   |   |   | X | X | X |
| A12. Escritura del Documento Final             |   |   |   | X | X | X | X | X |

**Tabla I.** : Cronograma de actividades integral: desarrollo técnico, experimentación y documentación final.

## 7. RECURSOS Y ASPECTOS ECONÓMICOS

| TIPO DE RECURSO     | DESCRIPCIÓN                                                                                                                                                                                                                                                                                                                     |
|---------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Capital Humano      | <b>Estudiante investigador:</b> Frank Edward Daza Gonzalez.<br><b>Director:</b> Julián Hurtado López.<br><b>Codirectora:</b> Alba Marcela Herrera Trujillo.                                                                                                                                                                     |
| Tecnologías Blandas | <b>Software:</b> Python, PyTorch, PennyLane.<br><b>Herramientas:</b> Repositorios públicos (Kaggle), <i>Weights &amp; Biases</i> para monitoreo de sobreajuste y <i>Overleaf Pro</i> para documentación.<br><b>Metodología:</b> Diseño experimental cuantitativo con validación cruzada ( $k = 5$ ).                            |
| Tecnologías Duras   | Equipo de cómputo personal y servicios de cómputo de alto rendimiento en la nube (Google Colab Pro+) para simulación de circuitos cuánticos y entrenamiento de modelos SOTA.                                                                                                                                                    |
| Infraestructura     | No se requiere laboratorio físico. Modalidad de trabajo remoto utilizando servicios de almacenamiento en la nube (Google One).                                                                                                                                                                                                  |
| Financieros         | <b>Financiación propia:</b> Se estima un presupuesto operativo de aproximadamente <b>\$704.00 USD</b> , desglosados en: <ul style="list-style-type: none"> <li>■ Cómputo (Colab Pro+): \$400.00</li> <li>■ Asistencia IA (Google AI Pro): \$160.00</li> <li>■ Infraestructura y Escritura (Overleaf/Drive): \$144.00</li> </ul> |

## REFERENCIAS

- Abbas, A., Sutter, D., Zoufal, C., Lucchi, A., Figalli, A., and Woerner, S. (2021). The power of quantum neural networks. *Nature Computational Science*, 1(6):403–409.
- Ait Haddou, M. and Bennai, M. (2025). Hqcm-ebtc: A hybrid quantum-classical model for explainable brain tumor classification. *arXiv preprint arXiv:2506.21937*.
- Bergadano, L. (2024). From quantum quirks to clear skies: A not-so-dusty road to sensor calibration. Master’s thesis, Politecnico di Torino.
- Bergholm, V., Izaac, J., Schuld, M., Gogolin, C., Alam, M. S., Ahmed, S., et al. (2018). PennyLane: Automatic differentiation of hybrid quantum-classical computations. *arXiv preprint arXiv:1811.04968*.
- Bharti, K., Cervera-Lierta, A., Kyaw, T. H., Haug, T., Alperin-Lea, S., Anand, A., Degroote, M., Heimonen, H., Kottmann, J. S., Menke, T., Mok, W. C., Sim, S., Soeken, M., Vizzotto, J. C., and Wiebe, N. (2022). Noisy intermediate-scale quantum (NISQ) algorithms. *Reviews of Modern Physics*, 94(1):015004.
- Cerezo, M., Sone, A., Volkoff, T., Cincio, L., and Coles, P. J. (2021). Cost function dependent barren plateaus in shallow quantum neural networks. *Nature Communications*, 12(1):1791.
- Dutta, T., Pérez-Salinas, A., Phua Sing Cheng, J., Latorre, J., and Mukherjee, M. (2022). Single-qubit universal classifier implemented on an ion-trap quantum device. *Physical Review A*, 106(1):012411.
- Esteva, A., Chou, K., Yeung, S., Naik, N., Madani, A., Mottaghi, R., Kasstein, Y., Tan, R., Nguyen, T., Maggio, R., et al. (2019). A guide to deep learning in healthcare. *Nature medicine*, 25(1):24–29.
- Grant, E., Wossnig, L., Ostaszewski, M., and Benedetti, M. (2019). An initialization strategy for addressing barren plateaus in parametrized quantum circuits. *Quantum*, 3:214.
- Gupta, R. S., Wood, C. E., Engstrom, T., Pole, J. D., and Shrapnel, S. (2025). Quantum machine learning for digital health? a systematic review. *npj Digital Medicine*, 8:237.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778.

- Holmes, Z., Sharma, K., Cerezo, M., and Coles, P. J. (2022). Connecting ansatz expressibility to gradient magnitudes and barren plateaus. *PRX Quantum*, 3(1):010313.
- Khan, M. A.-Z., Galib, A. A. O., Innan, N., and Bennai, M. (2024). Brain tumor diagnosis using hybrid quantum convolutional neural networks. *arXiv preprint arXiv:2401.15804*. Preprint disponible en arXiv.
- Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A., van Ginneken, B., and Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical image analysis*, 42:60–88.
- Lusnig, L., Sagingalieva, A., Surmach, M., Protasevich, T., et al. (2024). Leveraging hybrid quantum neural networks for accurate liver steatosis classification. *Diagnostics*, 14(5):558.
- Mari, A., Bromley, T. R., Izaac, J., Schuld, M., and Killoran, N. (2020a). Transfer learning in hybrid classical–quantum neural networks. *Quantum*, 4:340.
- Mari, A., Bromley, T. R., Izaac, J., Schuld, M., and Killoran, N. (2020b). Transfer learning in hybrid classical-quantum neural networks. *Quantum*, 4:340.
- McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., and Neven, H. (2018). Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9(1):4812.
- Nickparvar, M. (2023). Brain tumor mri dataset (version 3).
- Preskill, J. (2018). Quantum computing in the NISQ era and beyond. *Quantum*, 2:79.
- Schuld, M. and Killoran, N. (2019). Quantum machine learning in feature hilbert spaces. *Physical Review Letters*, 122(4):040504.
- Shahjalal, J. K. F., Paul, P. C., Hossain, M. R., Ahmed, M. T., and Chakraborty, D. (2025). Hqcnn: A hybrid quantum-classical neural network for medical image classification. *arXiv preprint arXiv:2509.14277*. Preprint disponible en arXiv.
- Shahriyar, M. F. and Tanbhir, G. (2025). Advancements and challenges in quantum machine learning for medical image classification: A comprehensive review. *arXiv preprint arXiv:2504.13910*. Preprint disponible en arXiv.
- Tan, M. and Le, Q. (2019). Efficientnet: Rethinking model scaling for convolutional neural networks. In *International conference on machine learning*, pages 6105–6114. PMLR.
- Willemink, M. J., Koszek, W. A., Hardell, C., Wu, J., Fleischmann, D., Harvey, H., Folio, L. R., Summers, R. M., Rubin, D. L., and Lungren, M. P. (2020). Preparing medical imaging data for machine learning. *Radiology*, 295(1):4–15.