

Bitácora Metodológica de Hallazgos

Frank Daza

16 de agosto de 2026

Contenido

1. Propósito y convenciones

Este documento es el **registro empírico** de la ejecución del proyecto de grado. A diferencia del anteproyecto en `docs/proyecto_de_grado/`, que es prospectivo, la bitácora acumula evidencia conforme se completan las tareas del backlog. Cada hallazgo queda ligado a artefactos en `results/` y `models/`.

1.1 FLUJO DOCUMENTAL

El anteproyecto define el problema y el diseño metodológico. Esta bitácora registra lo ejecutado (tareas 3–16). El documento final (Trabajo de Grado - Frank Daza.tex, tarea 17) sintetiza los hallazgos con referencias cruzadas `\ref{hallazgo:task-N}`. Derivados posteriores: artículo científico (tarea 18) y ponencia (tarea 19).

1.2 TRAZABILIDAD OBLIGATORIA

Toda tarea del backlog que produzca evidencia experimental debe registrar un hallazgo con la etiqueta `\label{hallazgo:task-N}`, donde N es el identificador numérico de la tarea. Una tarea sin esta etiqueta se considera **no documentada**, aunque haya generado CSV en `results/`.

1.3 POLÍTICA DE BIBLIOGRAFÍA

La bibliografía es **compartida** con el anteproyecto: `docs/proyecto_de_grado/Referencias.bib`. Está prohibido duplicar entradas en un `.bib` local. Las citas nuevas se agregan con el skill `agregar-cita` sobre el archivo compartido. Motor: `natbib + estilo apalike`.

1.4 PLANTILLA ESTÁNDAR DE HALLAZGO

Toda tarea posterior debe replicar la siguiente estructura en el fragmento `hallazgos/` que corresponda a su fase:

```
\subsubsection{Task-N: Título de la tarea}
\label{hallazgo:task-N}
\begin{tabularx}{\textwidth}{|l|X|}\hline
\textbf{Fecha} & YYYY-MM-DD \\\hline
\textbf{Actividad} & A# del anteproyecto \\\hline
\textbf{Artefactos} & \texttt{results/...}, \texttt{models/...} \\\hline
\end{tabularx}

\paragraph{Objetivo.} Qué se buscaba verificar.
\paragraph{Procedimiento.} Resumen reproducible (semilla, hiperparámetros, comando \texttt{uv run}).
\paragraph{Resultados.} Tablas y figuras con \texttt{\textbackslash input} desde \texttt{results/figures/}.
\paragraph{Interpretación.} Qué implica para la hipótesis de eficiencia de datos.
\paragraph{Decisiones.} Cambios congelados (p.\,ej.\ $L=4$) o riesgos abiertos.
\paragraph{Limitaciones.} Sesgos, supuestos, deuda técnica.
```

1.5 MAPEO DE FRAGMENTOS POR FASE

Fragmento	Tareas
h0_fundamentos.tex	1, 2, 3, 4, 5, 6
h1_arquitectura.tex	7, 8, 9, 10, 11
h2_experimentacion.tex	12, 13
h3_analisis.tex	14, 15, 16

2. Fase 0 — Fundamentos reproducibles y datos

2.0.1 Task-1: Infraestructura y entorno reproducible

Fecha	2026-08-16
Actividad	Infraestructura (m-0)
Artefactos	src/config.py, src/utils/seed.py, src/utils/device.py, src/smoke.py, uv.lock, .python-version

Objetivo. Establecer un entorno reproducible con una única fuente de hiperparámetros, semilla global fijada y selección de dispositivo `cuda >mps >cpu`.

Procedimiento. Se implementó `ExperimentConfig` como dataclass congelada, `set_seed(42)` con `torch.use_deterministic_algorithms(True, warn_only=True)` y `get_device()` con la prelación definida en `AGENTS.md`. Verificación con:

```
uv run python -m src.smoke
```

Resultados. Stack congelado: Python 3.12, PyTorch 2.9.1, torchvision 0.24.1, PennyLane 0.45.1, NumPy $\geq 2.0, < 2.3$. Dispositivo detectado: **mps**. Pérdida de referencia (dos corridas idénticas): **1.54205954**. Resultado reproducibilidad: **PASS**.

Interpretación. El entorno local cumple el criterio de reproducibilidad bit a bit dentro del mismo dispositivo. La semilla 42 queda fijada por convención del anteproyecto.

Decisiones. Semilla global 42 en `ExperimentConfig.semilla`. Gestor de paquetes exclusivo: UV (`uv sync --frozen`). Dispositivo registrado en cada corrida (contrato de tarea 4).

Limitaciones. La reproducibilidad bit a bit solo se garantiza dentro del mismo dispositivo; en `mps` algunas operaciones caen a CPU sin equivalente completo de `torch.cuda.manual_seed_all`.

2.0.2 Task-2: Estructura LaTeX del trabajo de grado y bitácora de hallazgos

Fecha	2026-08-16
Actividad	Documentación (m-0)
Artefactos	<code>docs/trabajo_de_grado/</code> (bitácora, preámbulo, esqueleto de tesis, fragmentos hallazgos/)

Objetivo. Crear la estructura LaTeX del documento final y la bitácora metodológica de hallazgos, con trazabilidad `task-N` $\leftrightarrow$ artefactos en `results/`.

Procedimiento. Se copió el preámbulo UAO del anteproyecto a `preambulo_uao.tex` sin modificar el original. Se crearon los fragmentos `h0_fundamentos.tex` a `h3_analisis.tex`, el esqueleto Trabajo de Grado - Frank Daza.tex con capítulos vacíos y la cadena de compilación `pdflatex` $\rightarrow$ `bibtex` $\rightarrow$ `pdflatex` contra `../proyecto_de_grado/Referencias.bi`

Resultados. Estructura creada en `docs/trabajo_de_grado/`: `preambulo_uao.tex`, bitácora, esqueleto de tesis, carpetas `hallazgos/`, `capitulos/` y `Figuras/` (logo UAO). Bibliografía compartida sin entradas duplicadas. Cita de verificación: Penny-Lane ?.

Interpretación. A partir de esta tarea, cada hallazgo experimental se registra en el fragmento de fase correspondiente. El documento final (tarea 17) sintetizará esta evidencia con `\ref{hallazgo:task-N}` en lugar de reconstruir resultados desde CSV.

Decisiones. Preámbulo copiado (no refactorizado) del anteproyecto entregado. Fragmentos sin espacios en el nombre de archivo. Logo UAO copiado (no symlink) para portabilidad entre máquinas.

Limitaciones. Los documentos principales (Bitacora Metodologica de Hallazgos.tex, Trabajo de Grado - Frank Daza.tex) llevan espacios en el nombre; la compilación requiere comillas en la línea de comandos.

2.0.3 Task-3: Auditoría del Brain Tumor MRI Dataset (A4)

Fecha	2026-08-17
Actividad	A4 — Curaduría y auditoría del dataset (m-0)
Artefactos	src/data/audit.py, results/dataset_manifest.csv, results/dataset_audit.md, results/figures/distribucion_clases.png

Objetivo. Verificar el conteo real, el balance por clase y partición, la integridad de las imágenes y la presencia de duplicados exactos antes de diseñar escenarios de escasez, siguiendo buenas prácticas de preparación de datos en imagen médica ?.

Procedimiento. Dataset local en notebooks/data/, enlazado por symlink a data/brain_tumor (ruta de ExperimentConfig). Recorrido estable con pathlib, verificación PIL (verify + load), hash SHA-256 de contenido y clasificación de duplicados en tres categorías. Ejecución:

```
uv run python -m src.data.audit
```

Resultados. Total inventariado: **7023** imágenes (coincide con el anteproyecto). Extensiones: solo .jpg. Imágenes corruptas: **0**. Duplicados exactos (grupos con $n > 1$): intra clase **194**, entre clases **0**, Training↔Testing **79**. Exclusiones: **297** filas (duplicado_exacto: 194; fuga_train_test: 103). Utilizables: **6726**.

Clase	Testing	Training	Total
glioma	300	1321	1621
meningioma	306	1339	1645
notumor	405	1595	2000
pituitary	300	1457	1757
Total	1311	5712	7023

Heterogeneidad: modos L (3093), RGB (3926), P/RGBA (4); resolución dominante 512×

512 (4742 imágenes). Las cuatro clases corresponden a categorías del sistema nervioso central en la clasificación WHO 2021 ?.

Figura 1: Distribución de clases por partición (imágenes no excluidas).

Interpretación. El dataset agregado de Nickparvar ? es heterogéneo en modo de color y resolución; la auditoría confirma que el tamaño declarado es correcto pero existen duplicados exactos y fuga potencial entre Training/ y Testing/. Sin esta verificación, la exactitud de modelos posteriores podría inflarse por memorización de copias idénticas ?.

Decisiones. Unir Training/ y Testing/ al conjunto completo para validación cruzada estratificada $k = 5$ (decisión D1, TASK-6); no se usa Testing/ como holdout externo. Las exclusiones quedan en `dataset_manifest.csv` mediante columnas `excluida` y `motivo_exclusion`.

Limitaciones. El hash SHA-256 detecta duplicados byte a byte, no re-codificaciones JPEG con distinta compresión. La conversión a 3 canales y el redimensionado a 224×224 se documentan en TASK-5.

2.0.4 Task-5: Pipeline de preprocesamiento y aumento de datos (A5)

Fecha	2026-08-17
Actividad	A5 — Preprocesamiento y aumento de datos (m-0)
Artefactos	<code>src/data/transforms.py</code> , <code>src/data/dataset.py</code> , <code>src/data/loaders.py</code> , <code>tests/test_transforms.py</code> , <code>tests/test_dataset.py</code> , <code>results/figures/ejemplos_aumento.png</code>

Objetivo. Definir el pipeline de entrada para los *backbones* preentrenados en ImageNet: redimensionado a 224×224 , normalización con las estadísticas de ImageNet y aumento de datos **únicamente en entrenamiento**, siguiendo buenas prácticas de preparación de datos en imagen médica ??.

Procedimiento. Transformaciones declaradas en `construir_transformaciones()` (API `torchvision.transforms.v2`, sin mezclar con la API clásica):

1. `Resize((224, 224))`

2. **Solo entrenamiento:** `RandomRotation( $\pm 10^\circ$ , fill=0)` y `RandomHorizontalFlip(p=0.5)`
3. `ToImage()` $\rightarrow$ `ToDtype(float32, scale=True)`
4. `Normalize(mean=(0.485, 0.456, 0.406), std=(0.229, 0.224, 0.225))`

El `MRIDataset` lee del manifiesto auditado (TASK-3), convierte siempre a RGB (incluidas imágenes en modo L) y mapea la etiqueta con `MAPEO_CLASE` alineado a TASK-4. Los `DataLoader` usan `generator` y `WorkerInitFn` (serializable en `spawn`) para reproducibilidad con `num_workers > 0`. Verificación:

```
uv run pytest tests/test_transforms.py tests/test_dataset.py -q
```

Resultados. Toda imagen sale como tensor `float32` de forma $(3, 224, 224)$. Pruebas automatizadas: **10 passed** (determinismo en validación, variación en entrenamiento, contrato de forma, grises a 3 canales, loader determinista con 2 workers).

Figura 2: Ejemplos de preprocesamiento: original, validación (sin aumento) y entrenamiento (con rotación leve y volteo horizontal).

Interpretación. Los *backbones* `EfficientNet-B0` y `ResNet-50` esperan entradas calibradas con ImageNet ?; normalizar con estadísticas del dataset propio degradaría las características transferidas de un modelo congelado. El aumento se aplica **después** de fijar las particiones (TASK-6): aumentar antes de partir filtraría variantes de la misma imagen entre entrenamiento y validación.

Decisiones. **Volteo horizontal** ($p = 0,5$): defendible por la simetría aproximada del cerebro en cortes axiales. **Rotaciones leves** ($\pm 10^\circ$): variabilidad de posicionamiento del paciente sin distorsionar la anatomía. **Volteo vertical descartado**: produce anatomías imposibles en MRI axial. `fill=0` en rotación: coherente con el fondo negro típico de MRI. Validación y prueba **nunca** reciben aumento.

Limitaciones. El aumento no sustituye la auditoría de duplicados (TASK-3). La justificación anatómica no garantiza que toda variante sintética sea clínicamente plausible; un aumento agresivo introduciría sesgo en lugar de robustez ?.

2.0.5 Task-6: Protocolo de particiones — holdout, k-fold estratificado y fracciones (A7)

Fecha	2026-08-17
Actividad	A7 — Diseño de escenarios de escasez; base de A8 (m-0)
Artefactos	src/data/splits.py, results/splits.json, results/splits_summary.md, tests/test_splits.py

Objetivo. Fijar un protocolo único de particiones para que los tres modelos (HQCNN, EfficientNet-B0, ResNet-50) vean exactamente los mismos datos en cada celda del diseño factorial $3 \times 4 \times 5$, evitando que diferencias entre arquitecturas se confundan con ruido de remuestreo ???.

Procedimiento. Sobre el manifiesto auditado (6726 imágenes utilizables, TASK-3), ordenado por `ruta_relativa` con `mergesort`:

1. StratifiedKFold con $k = 5$, `shuffle=True`, `random_state=42` sobre el conjunto completo (decisión D1).
2. Validación de tamaño **fijo** por fold; idéntica en las cuatro fracciones.
3. Submuestreo estratificado **anidado** solo del entrenamiento en cascada 100 % → 50 % → 25 % → 10 % con `StratifiedShuffleSplit` y `train_size` entero.
4. Persistencia determinista en `results/splits.json` con hash SHA-256 del manifiesto y validación al cargar.

Ejecución:

```
uv run python -m src.data.splits
uv run pytest tests/test_splits.py -q
```

Decisión D1 frente a la redacción literal de A8. El anteproyecto prescribe validación cruzada estratificada en cada escenario de escasez. La lectura literal — submuestrear primero al 10 % y *luego* partir en folds— dejaría ~ 140 imágenes de validación por fold al 10 %, con varianza que dominaría el efecto buscado. Se adopta el orden inverso: **folds fijos primero; escasez solo en entrenamiento**. Así las

curvas de escasez miden *cantidad* de datos y no *identidad* de los datos (anidamiento garantizado). La validación fija también reduce la inestabilidad de estimadores por *split* único en imagen médica ?.

Resultados. Artefacto: results/splits.json (5 folds $\times$ 4 fracciones). Hash del manifiesto: 30fb5b43...129ca. Pruebas automatizadas: **9 passed** (anidamiento, estratificación $\pm 2\%$, disyunción train/val, validación idéntica entre fracciones, determinismo, hash).

Piso del escenario más extremo (10 % de entrenamiento, fold 0):

Fracción	Total train	glioma	meningioma	pituitary	notumor
0.10	538	130	131	139	138
0.25	1345	324	327	348	346
0.50	2690	648	654	696	692
1.00	5380	1296	1308	1392	1384

Validación fold 0: 1346 imágenes (constante en las cuatro fracciones). Mínimo por clase al 10 %: 130 imágenes ($\gg$ batch_size=32).

Interpretación. Persistir índices en disco convierte la comparación entre modelos en **pareada** y la campaña en reanudable: el Trainer (TASK-8) leerá obtener_indices() y nunca remuestreará. Sin anidamiento, una caída de exactitud al 10 % no distinguiría “menos datos” de “otros datos”.

Decisiones. Fracciones: 10 %, 25 %, 50 %, 100 %. Semilla global 42; semilla de submuestreo por fold: semilla + k. Tolerancia de estratificación declarada: $\pm 2\%$ respecto a la proporción global. drop_last=True en entrenamiento cuando el último lote sea de tamaño 1 (documentado para TASK-8).

Limitaciones. Los 5 folds **comparten** observaciones entre sí: no son 5 muestras independientes. Esta no independencia condiciona la ANOVA de TASK-15 y debe declararse en el análisis estadístico. Si el manifiesto cambia sin regenerar splits.json, los índices apuntan a otras imágenes sin error visible: por eso se valida el hash al cargar.

2.0.6 Task-4: Contrato de métricas, logging y artefactos

Fecha	2026-08-17
Actividad	Infraestructura (m-0) — contrato de resultados
Artefactos	src/logging/records.py, src/logging/sinks.py, src/logging/timing.py, tests/test_records.py, tests/test_sinks.py

Objetivo. Definir **antes de entrenar** el esquema único de resultados del proyecto: una fila por corrida (`modelo`, `data_fraction`, `fold`, `semilla`) con todas las métricas que exigen A9 y A10, más un historial por época en JSON para las curvas de A11. En problemas clínicos multiclase, la exactitud sola es insuficiente: deben reportarse sensibilidad y especificidad por clase ?.

Procedimiento. Se implementaron las dataclasses congeladas `RunRecord` y `EpochRecord` con validación explícita (`validar()`), la función `aplanar()` que alimenta CSV y wandb desde el mismo objeto, y los *sinks* de persistencia. El protocolo de tiempos exige descartar al menos 3 lotes de calentamiento, sincronizar el dispositivo (`cuda/mps`) antes y después de cada medición, y reportar la mediana de milisegundos por lote en inferencia. Verificación:

```
uv run pytest tests/ -q
```

Resultados. Esquema tidy de `results/experiments.csv` (una observación por fila):

Grupo	Columna	Descripción
Identidad	modelo	Identificador del modelo (hqcnn, efficientnet_b0, etc.)
Identidad	data_fraction	Fracción del entrenamiento usada
Identidad	fold	Índice del fold estratificado
Identidad	semilla	Semilla global de la corrida
Contexto	dispositivo	cuda, mps o cpu
Contexto	n_train, n_val	Tamaños de particiones
Contexto	epocas	Presupuesto de épocas
Contexto	n_params_entrenables	Parámetros con gradiente
Contexto	n_capas_vqc	Profundidad L del VQC (None en clásicos)
Contexto	commit_sha	SHA corto del commit (-dirty si aplica)
Contexto	timestamp	Marca temporal ISO 8601 de la corrida
Exactitud	accuracy_train, accuracy_val	Exactitud final
Pérdida	loss_train, loss_val	Pérdida media final
F1 (A9)	f1_val_weighted, f1_val_macro	F1 ponderado y macro
Por clase	sens_*, spec_*	Sensibilidad y especificidad por clase
Costo	train_time_s, inference_ms_per_batch	Tiempos medidos
Derivada	brecha_g	$ Acc_{train} - Acc_{val} $ (A11)

Historial por época en `results/history/{modelo}_{fraccion}_f{fold}_s{semilla}.json` con campos `epoca`, `loss_train`, `loss_val`, `accuracy_train`, `accuracy_val`. Pruebas automatizadas: **15 passed**.

Interpretación. El contrato convierte A9, A10 y A11 en consultas sobre datos ya recogidos. Si faltara un campo (p.ej. especificidad por clase), habría que repetir corridas cuyo gradiente se calcula por regla de cambio de parámetros. El Trainer (TASK-8) emitirá `RunRecord` sin conocer el formato de salida (DIP).

Decisiones. Orden canónico de clases: `glioma`, `meningioma`, `pituitary`, `notumor` (alineado con TASK-9). Un solo esquema vía `aplanar()` para CSV y wandb. Cabeza CSV validada contra `COLUMNAS_CSV`; escritura incompatible aborta en lugar de desalinear filas. Historial incluye `semilla` en el nombre para evitar colisiones futuras.

Limitaciones. El CSV en modo *append* no es seguro ante escritura paralela; si se paraleliza la campaña, escribir un CSV por corrida y consolidar en TASK-14. `wandb.init()` queda fuera del *sink*; el orquestador debe inicializar la sesión.

3. Fase 1 — Arquitectura híbrida CNN-VQC

4. Fases 2 y 3 — Experimentación y análisis

5. Síntesis de decisiones metodológicas

Esta sección consolida las decisiones congeladas a medida que avanza el proyecto:

- **D1** — Orden de particiones y fracciones de escasez (tarea 6).
- **D2** — Profundidad L del VQC y presupuesto de cómputo (tarea 11).
- **Go/no-go** — Criterio de viabilidad antes de la campaña experimental completa.

Las entradas se completarán conforme se ejecuten las tareas correspondientes.

Referencias

- Ait Haddou, M. and Bennai, M. (2025). Hqcm-ebtc: A hybrid quantum-classical model for explainable brain tumor classification. *arXiv preprint arXiv:2506.21937*.
- Bergholm, V., Izaac, J., Schuld, M., Gogolin, C., Alam, M. S., Ahmed, S., et al. (2018). PennyLane: Automatic differentiation of hybrid quantum-classical computations. *arXiv preprint arXiv:1811.04968*.
- Louis, D. N., Perry, A., Wesseling, P., Brat, D. J., Cree, I. A., Figarella-Branger, D., Hawkins, C., Ng, H., Pfister, S. M., Reifenberger, G., et al. (2021). The 2021 who classification of tumors of the central nervous system: a summary. *Neuro-oncology*, 23(8):1231–1251.
- Nickparvar, M. (2023). Brain tumor mri dataset (version 3).

Willemink, M. J., Koszek, W. A., Hardell, C., Wu, J., Fleischmann, D., Harvey, H., Folio, L. R., Summers, R. M., Rubin, D. L., and Lungren, M. P. (2020). Preparing medical imaging data for machine learning. *Radiology*, 295(1):4–15.